


Abordagens para minimizar o custo de rotulagem em CNNs

Áquila Oliveira Souza – 2021019327
Felippe Veloso Marinho – 2021072260

2025/2

Descrição do Problema – Introdução

- Redes convolucionais dependem fortemente de grandes volumes de dados rotulados.
- As CNNs geralmente precisam de muitos rótulos para bom desempenho.
- O processo de rotulagem é caro, lento e pouco escalável.



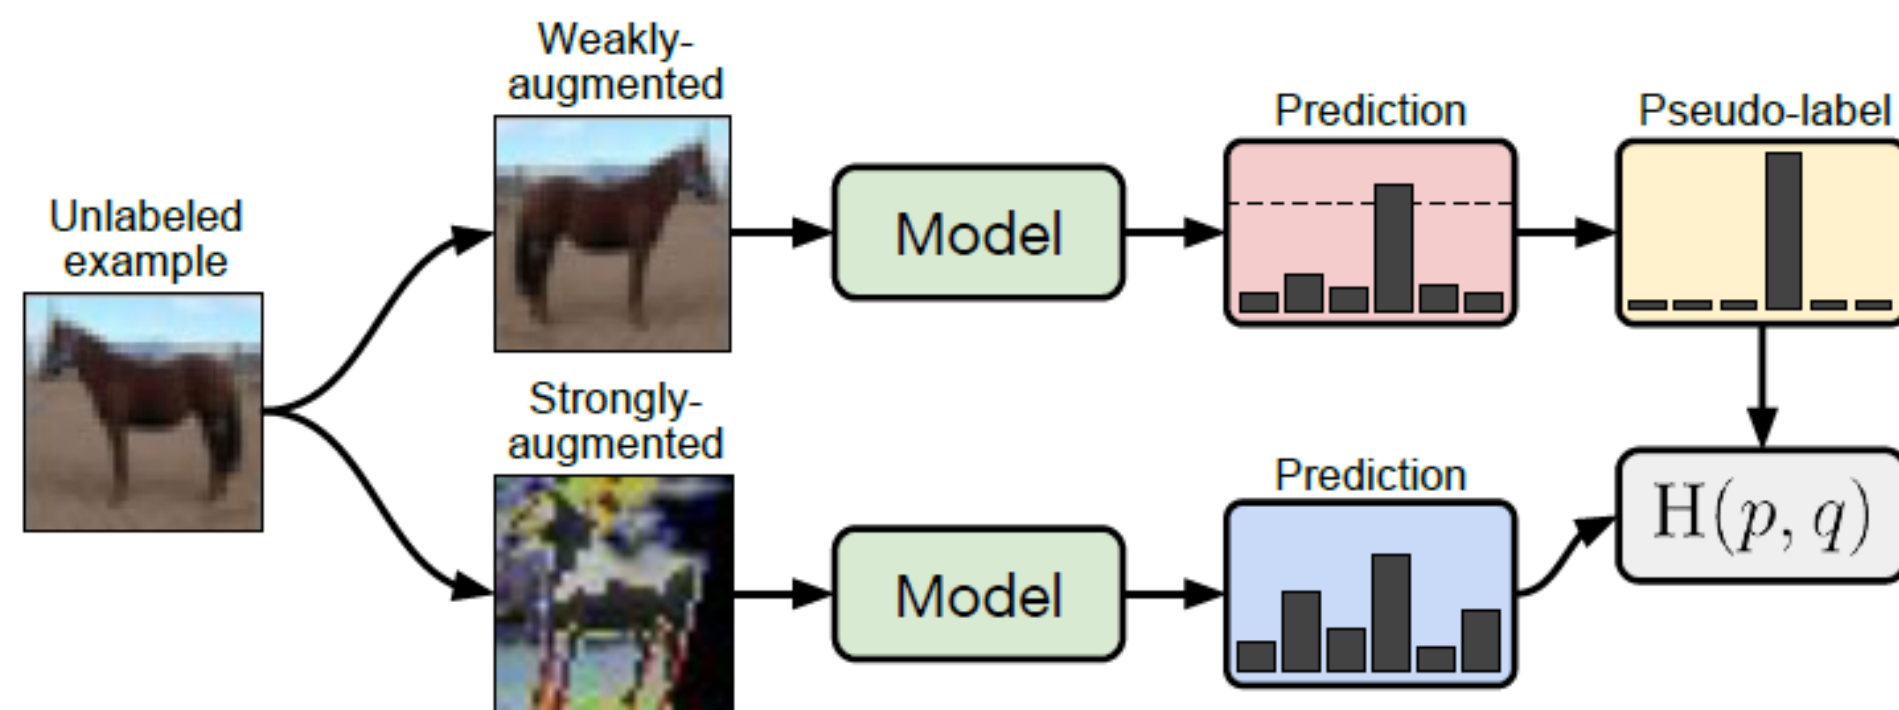
Revisão da Literatura – Paradigmas explorados

- Aprendizado Supervisionado (SL)
- Aprendizado Semi-Supervisionado (SSL)
- Aprendizado Ativo (AL)
- Autoaprendizado (Self-Supervised Learning)

Revisão da Literatura - Artigos de Referência

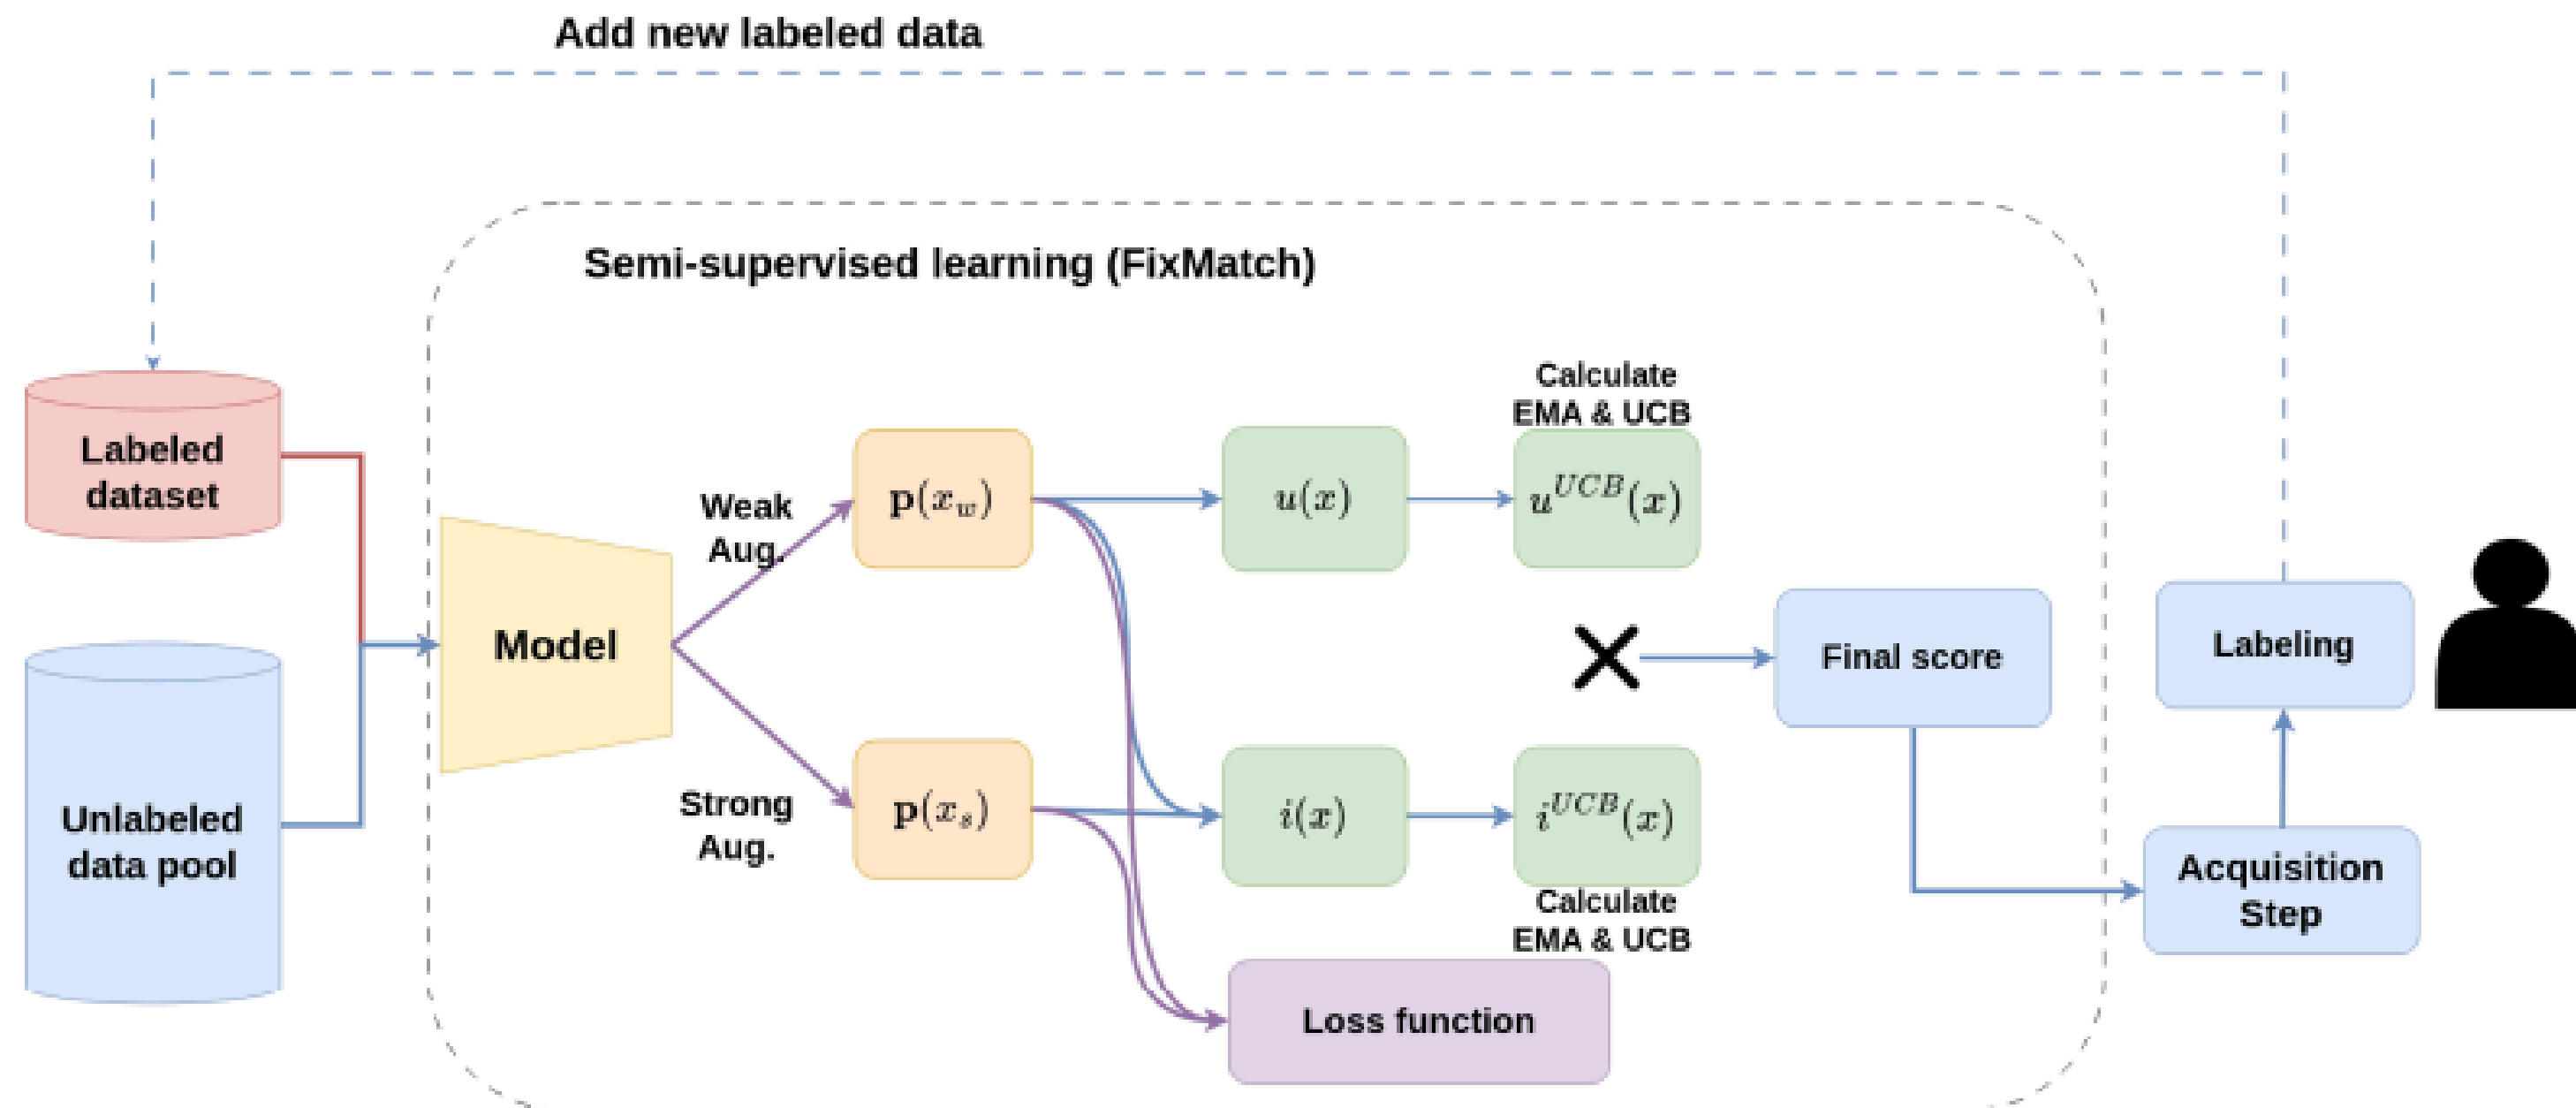
FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence

- Usa dados não rotulados para melhorar o treinamento.
- Foco: manter consistência das previsões sob pequenas perturbações.
- Método destaque: FixMatch (Sohn et al., 2020):
 - Pseudo-rótulos de alta confiança (confiança $> \tau$).
 - Consistência entre weak augmentation e strong augmentation.
- Alta eficácia mesmo com poucos rótulos reais.



Revisão da Literatura - Artigos de Referência

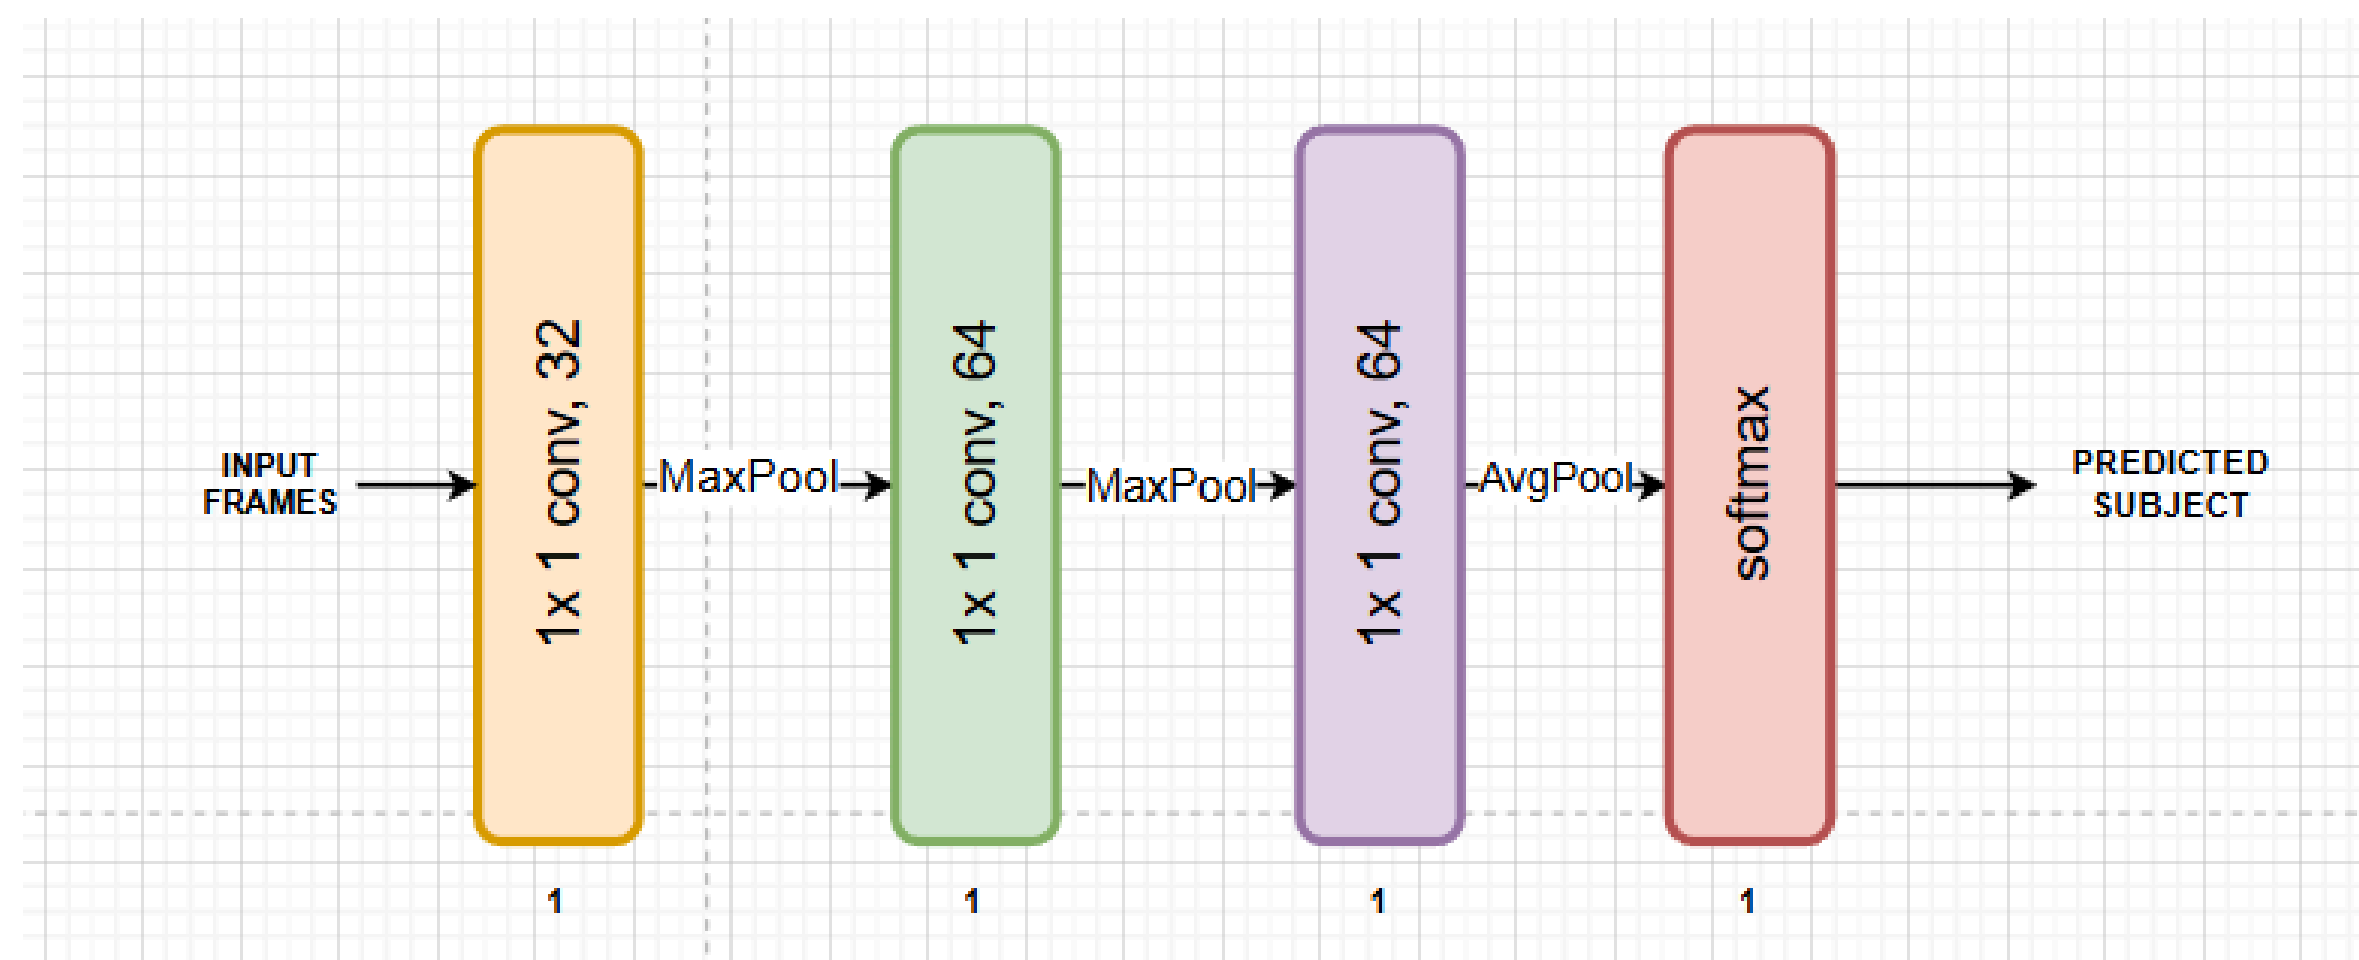
Active Semi-Supervised Learning by Exploring Per-Sample Uncertainty and Consistency



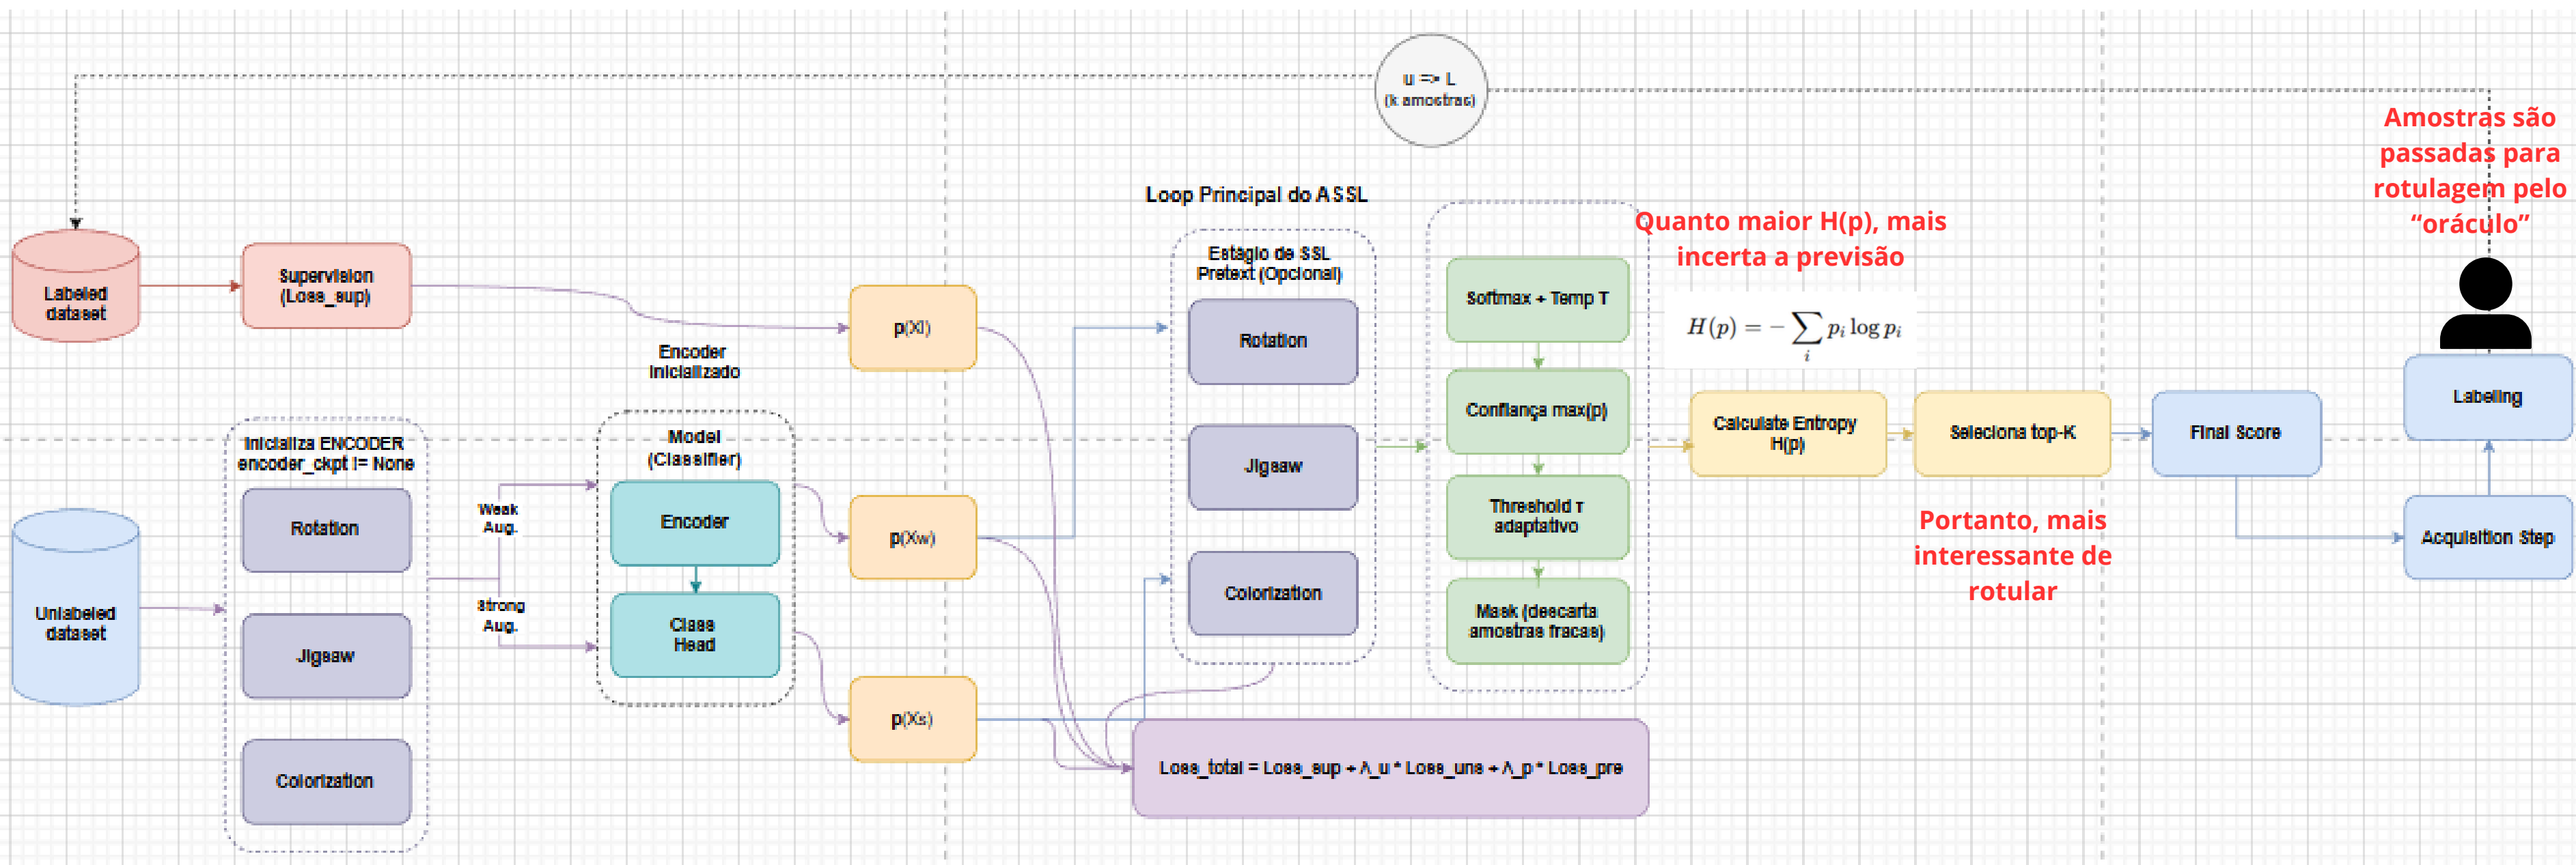
Nossa arquitetura

Small Encoder

- 110208 parâmetros;
- ResNet-18: 11,7 M;
- ResNet-50: 25,6 M;



Nosso pipeline - Rounds







pretext_task	λu	mean_acc	std_acc	mean_time (s)
colorization	1,0	8.635	754	82.277
none (SL puro)	0,0	4.958	236	9.890
none (SSL padrão)	1,0	8.135	1.313	67.013
rotation	1,0	9.169	276	76.853




Desempenho Geral

- **Sl puro**: Demonstra o problema de poucos dados rotulados, justificando o SSL.
- **SLL padrão**: Alta acc mas grande instabilidade (1,313), indica um resultado dependente da semente aleatória.
- **SSL com Colorização**: Alto desempenho de acc com resultado pouco inferior a tarefa com Rotação.
- **SSL com Rotação**: Maior acc para o dataset.


Resultados e Análise - Acc vs L_size



Resultados e Análise - Acc vs Round



Próximos Passos - Acc final vs Tempo total



- Eficácia da SSL Multitarefa: Pontos agrupados em torno de um tempo de execução maior com acc alta;
- Rotation apresenta pontos na região de maior acc com tempo médio menor em relação a colorization;

Conclusão

- O uso da Aprendizagem Semissupervisionada (SSL) é crucial para obter alta acurácia neste cenário de escassez inicial de dados rotulados.
- A incorporação de tarefas pretexto (multitarefa) melhora a acurácia e a estabilidade da SSL em comparação com o SSL puro, que é volátil.
- A Tarefa Pretexto de Rotação foi a mais indicada para esse dataset, pois forneceu a maior acurácia final média e a maior consistência entre as diferentes seeds.

Próximos Passos

- Testar para novos datasets (STL-10, CIFAR-10)
- Comparação com outros métodos que tem o mesmo objetivo (Constrative Learning)
- Testar em arquiteturas maiores com diferentes combinações dos pré-texto.