


# Abordagens para minimizar o custo de rotulagem em CNNs

Áquila Oliveira Souza – 2021019327  
Felippe Veloso Marinho – 2021072260

2025/2

# Descrição do Problema – Introdução

- Redes convolucionais dependem fortemente de grandes volumes de dados rotulados.
- As CNNs geralmente precisam de muitos rótulos para bom desempenho.
- O processo de rotulagem é caro, lento e pouco escalável.



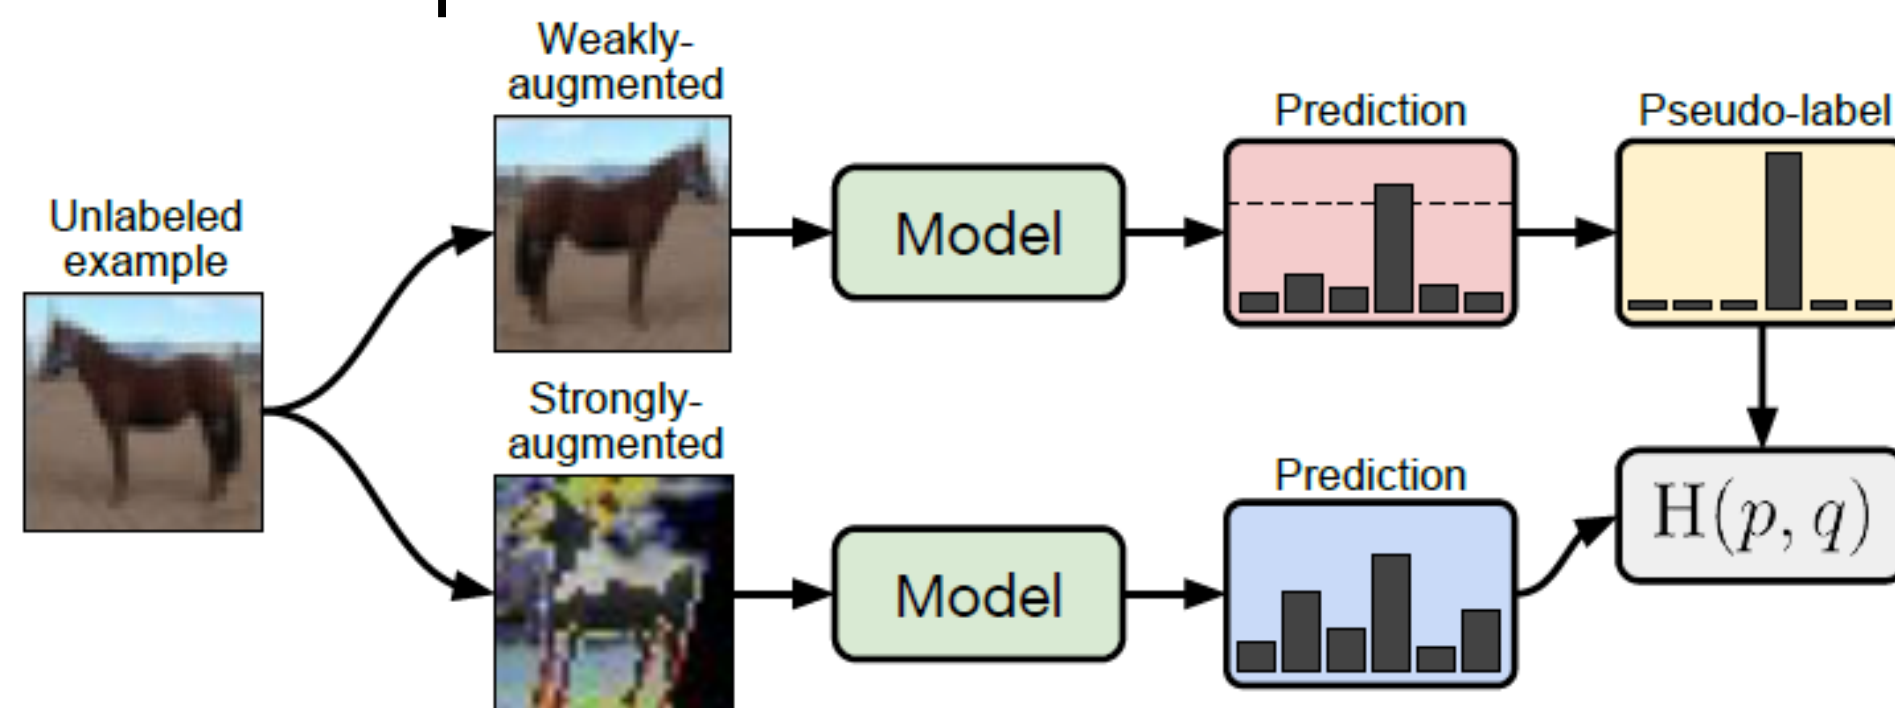
# Revisão da Literatura – Paradigmas explorados

- CNNs dependem de grandes quantidades de dados rotulados.
- Rotular é caro e pouco escalável.
- Aprendizado Semi-Supervisionado (SSL)
- Aprendizado Ativo (AL)
- Autoaprendizado (Self-Supervised Learning)

# Revisão da Literatura - Artigos de Referência

FixMatch: simplifica o Semi-Supervisionado (SSL)

- Usa dados não rotulados para melhorar o treinamento.
- Foco: manter consistência das previsões sob pequenas perturbações.
- Método destaque: FixMatch (Sohn et al., 2020):
  - Pseudo-rótulos de alta confiança (confiança  $> \tau$ ).
  - Consistência entre weak augmentation e strong augmentation.
- Alta eficácia mesmo com poucos rótulos reais.



## Algoritmo FixMatch

---

**Algorithm 1** FixMatch algorithm.

---

- 1: **Input:** Labeled batch  $\mathcal{X} = \{(x_b, p_b) : b \in (1, \dots, B)\}$ , unlabeled batch  $\mathcal{U} = \{u_b : b \in (1, \dots, \mu B)\}$   
confidence threshold  $\tau$ , unlabeled data ratio  $\mu$ , unlabeled loss weight  $\lambda_u$ .
  - 2:  $\ell_s = \frac{1}{B} \sum_{b=1}^B H(p_b, \alpha(x_b))$  {Cross-entropy loss for labeled data}
  - 3: **for**  $b = 1$  **to**  $\mu B$  **do**
  - 4:    $q_b = p_m(y \mid \alpha(u_b); \theta)$  {Compute prediction after applying weak data augmentation of  $u_b$ }
  - 5: **end for**
  - 6:  $\ell_u = \frac{1}{\mu B} \sum_{b=1}^{\mu B} \mathbb{1}\{\max(q_b) > \tau\} H(\arg \max(q_b), p_m(y \mid \mathcal{A}(u_b)))$  {Cross-entropy loss with pseudo-label and confidence for unlabeled data}
  - 7: **return**  $\ell_s + \lambda_u \ell_u$
-

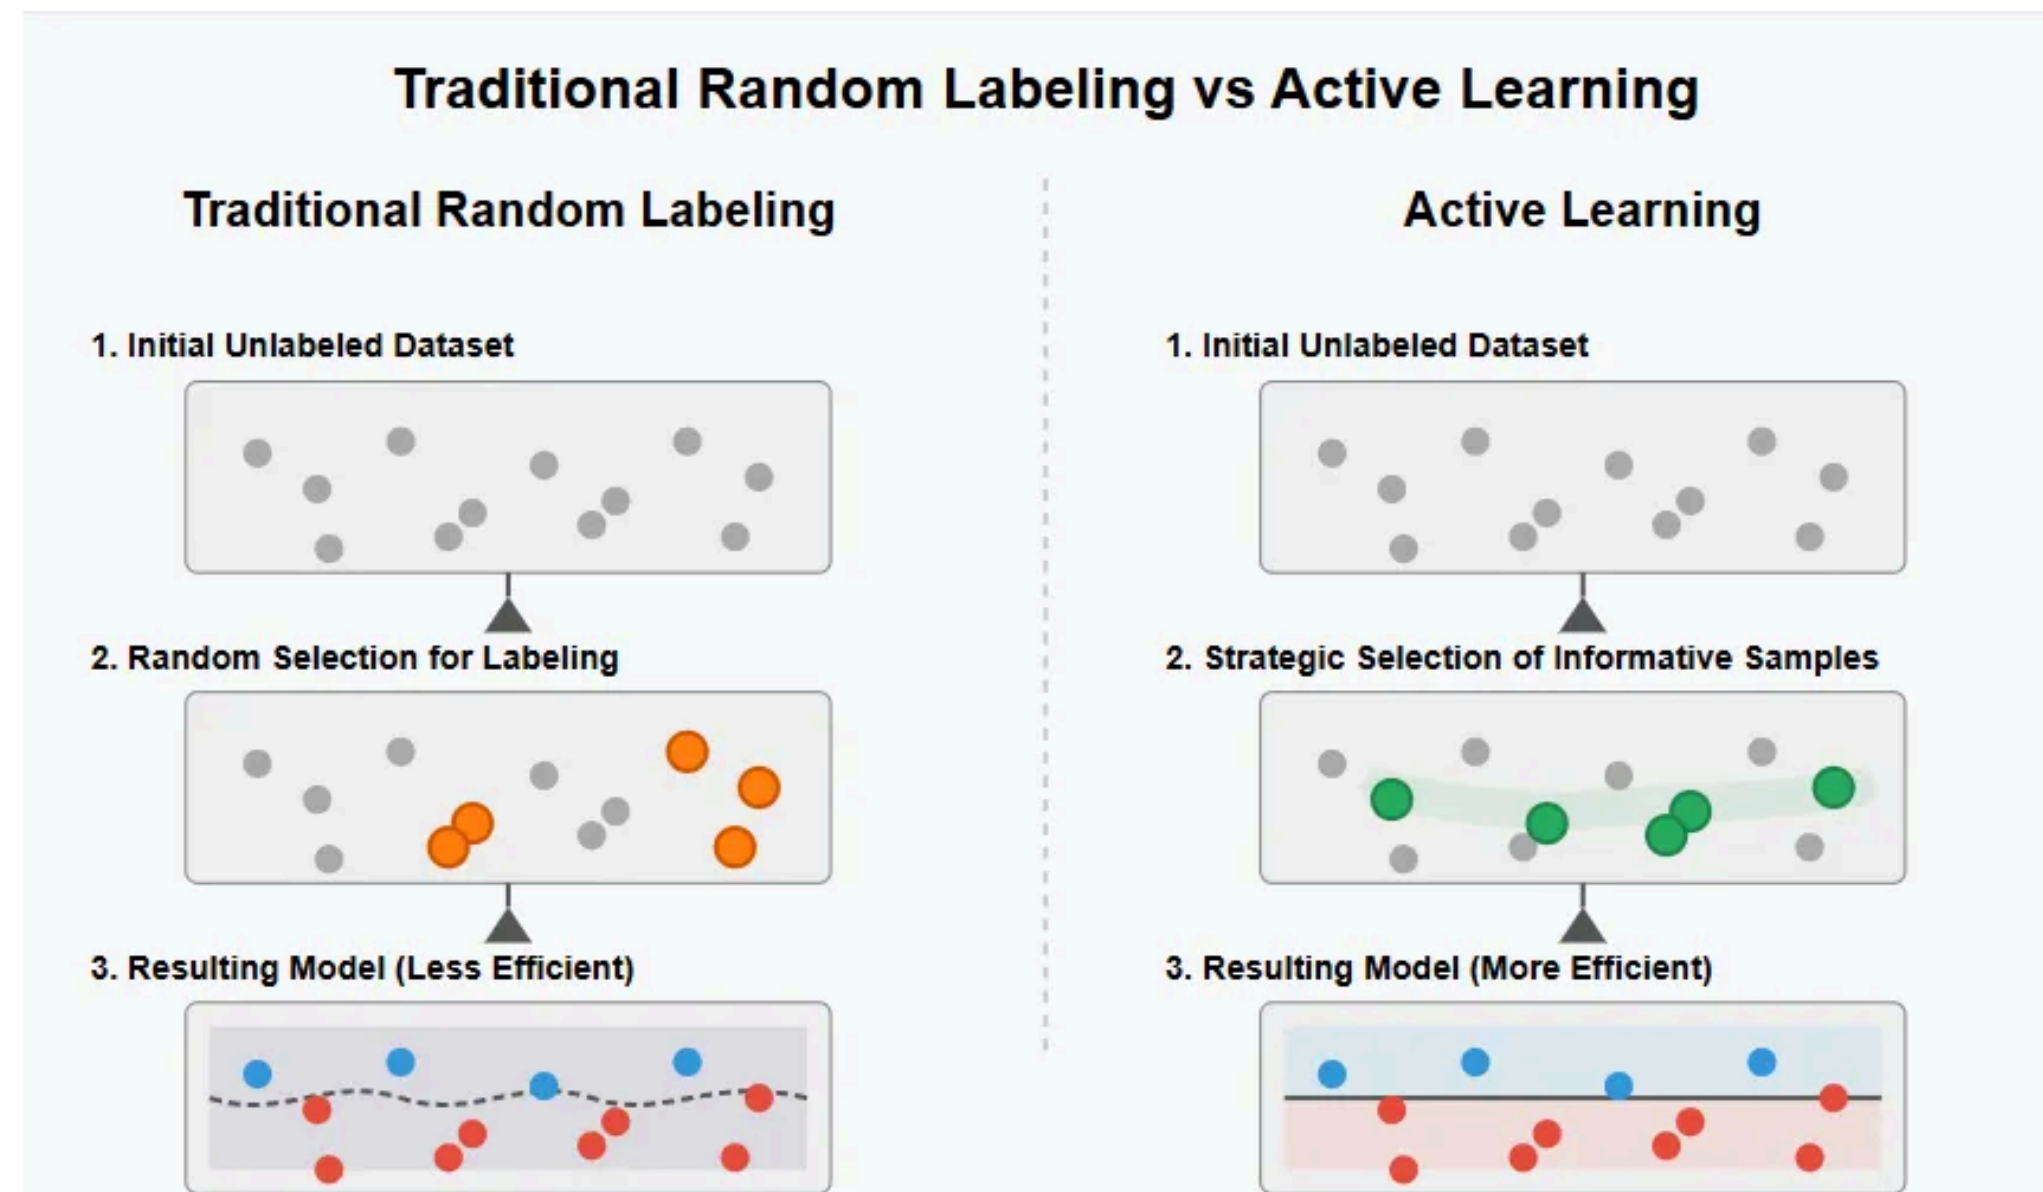
## Aprendizado Ativo + SSL (AS2L)

- SSL não garante que os rótulos escolhidos sejam os mais informativos.
- Active Learning seleciona amostras mais ambíguas para rotular.
- Integração: Active Semi-Supervised Learning.
- Método de referência (Luo et al., 2020):
- Seleção por incerteza (alta entropia).
- Seleção por baixa consistência (instabilidade sob perturbações).
- Objetivo: cada novo rótulo maximiza o ganho informacional.

# Revisão da Literatura - Artigos de Referência


## Aprendizado Ativo + SSL (AS2L)

- Em vez de seleção aleatória, a aprendizagem ativa identifica e rotula os pontos de dados mais informativos, melhorando drasticamente o desempenho.



# Revisão da Literatura - Artigos de Referência

## Active Semi-Supervised Learning by Exploring Per-Sample Uncertainty and Consistency

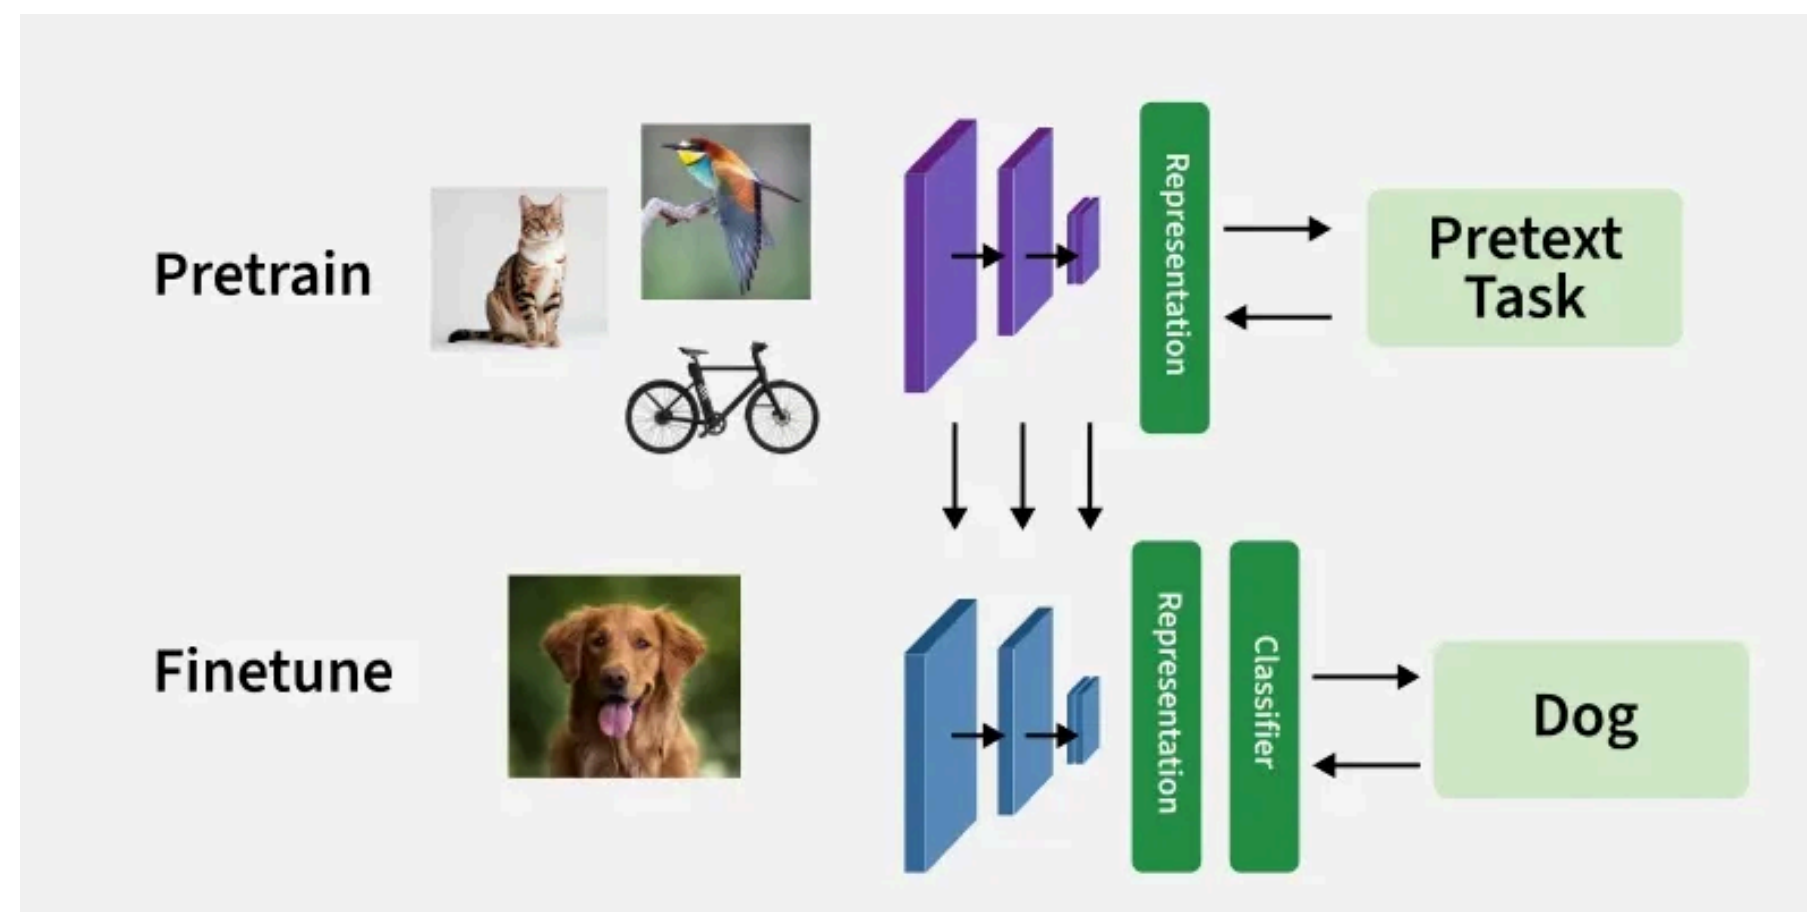




# Revisão da Literatura - Artigos de Referência

## Aprendizagem Auto-Supervisionada (SSL)

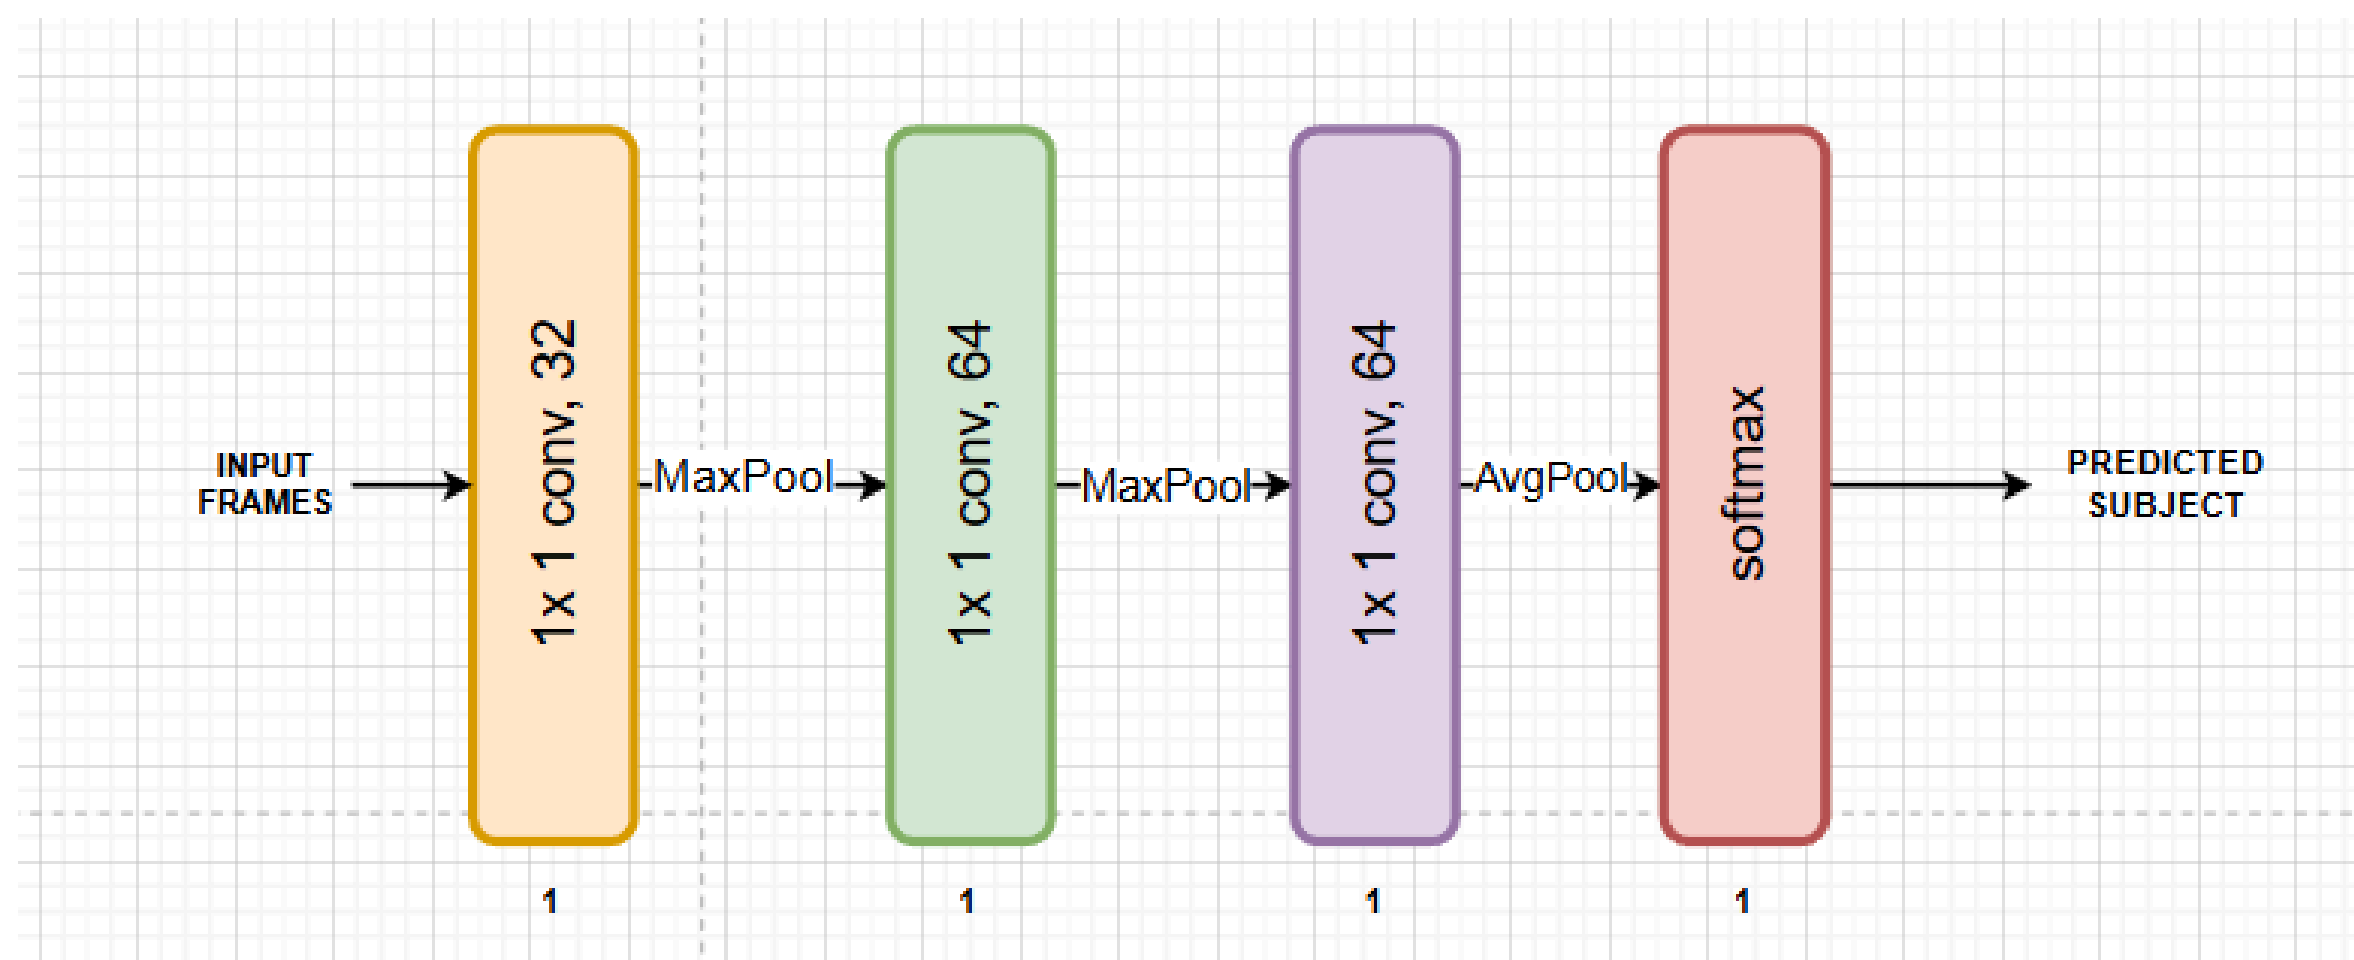
É um tipo de aprendizado em que um modelo é treinado usando dados que não possuem rótulos ou respostas fornecidas. Em vez de precisar que pessoas rotulem os dados, o modelo encontra padrões e cria seus próprios rótulos a partir dos dados automaticamente.



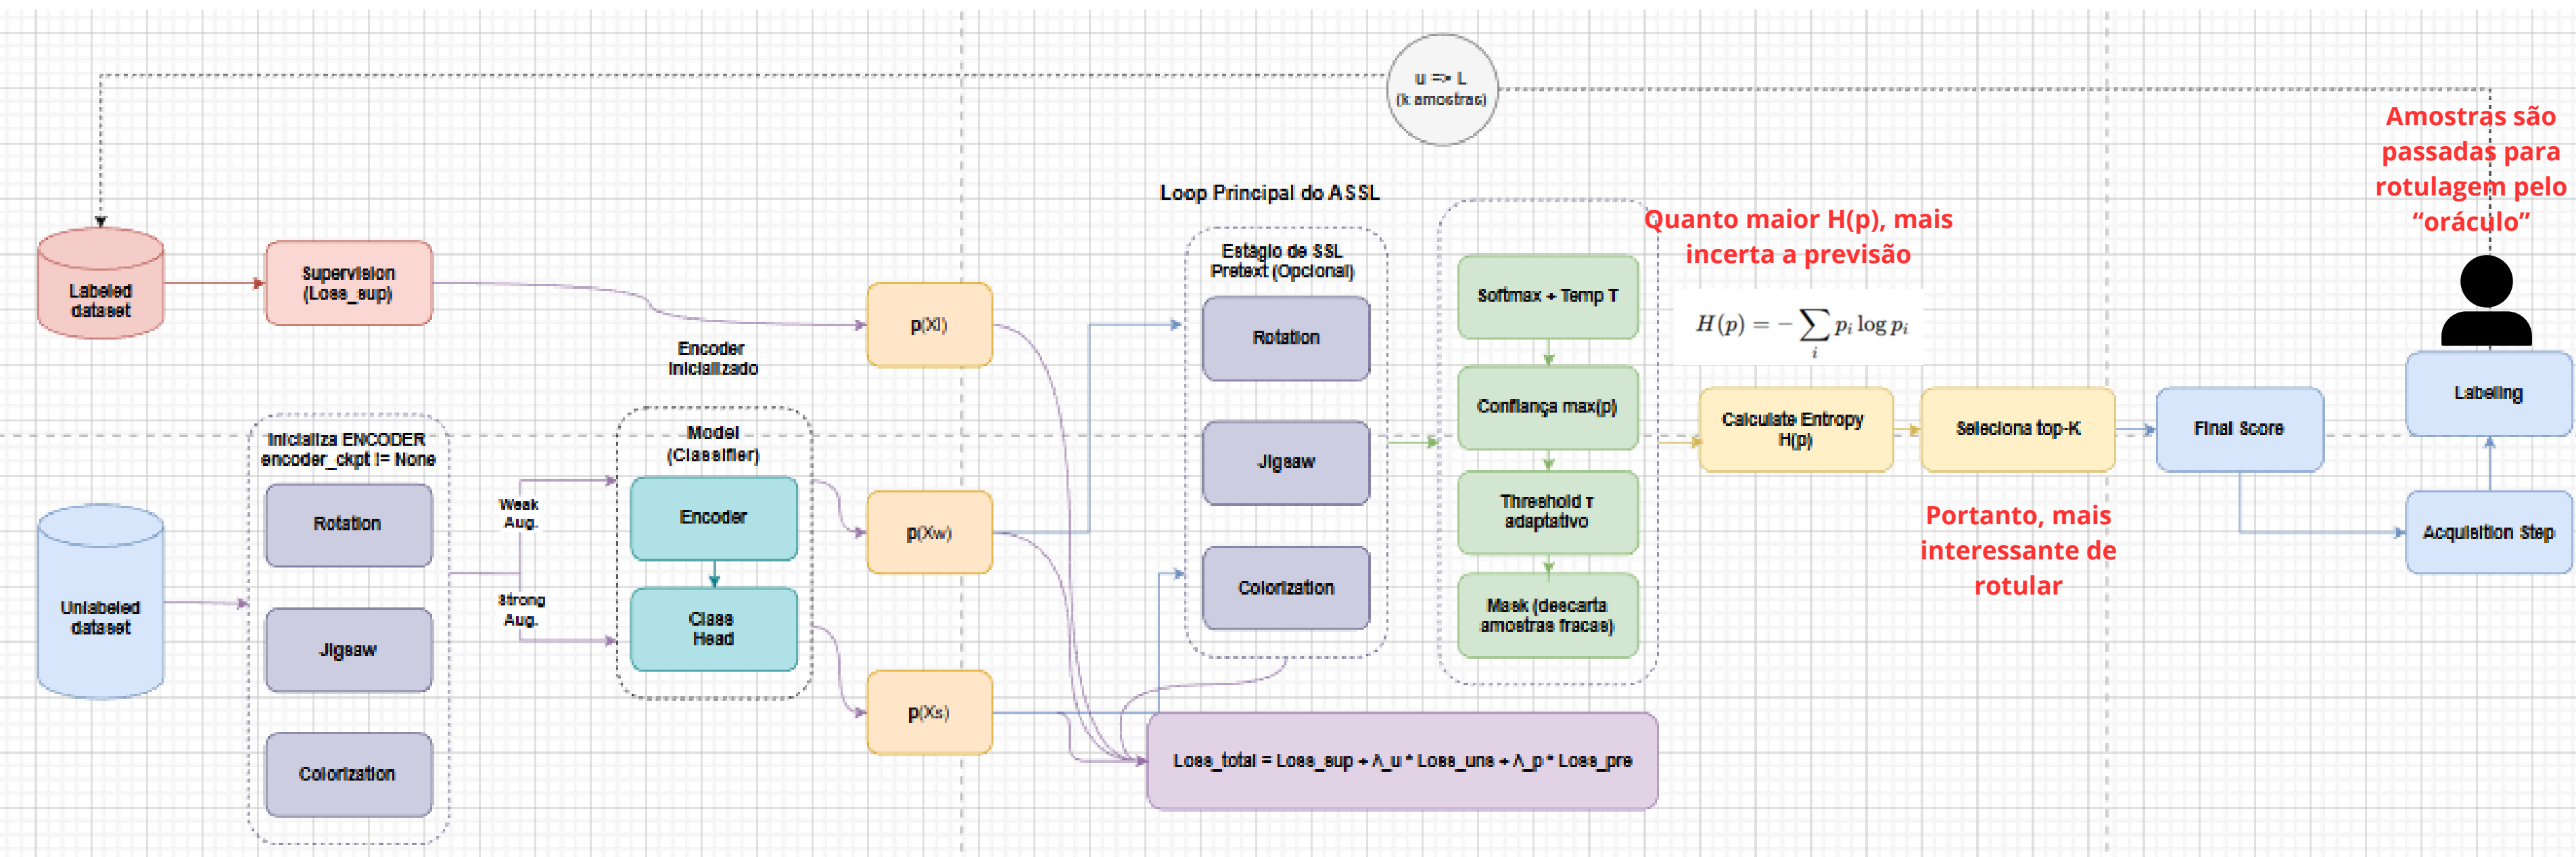
# Nossa arquitetura

## Small Encoder

- 110208 parâmetros;
- ResNet-18: 11,7 M;
- ResNet-50: 25,6 M;



# Nosso pipeline - Rounds

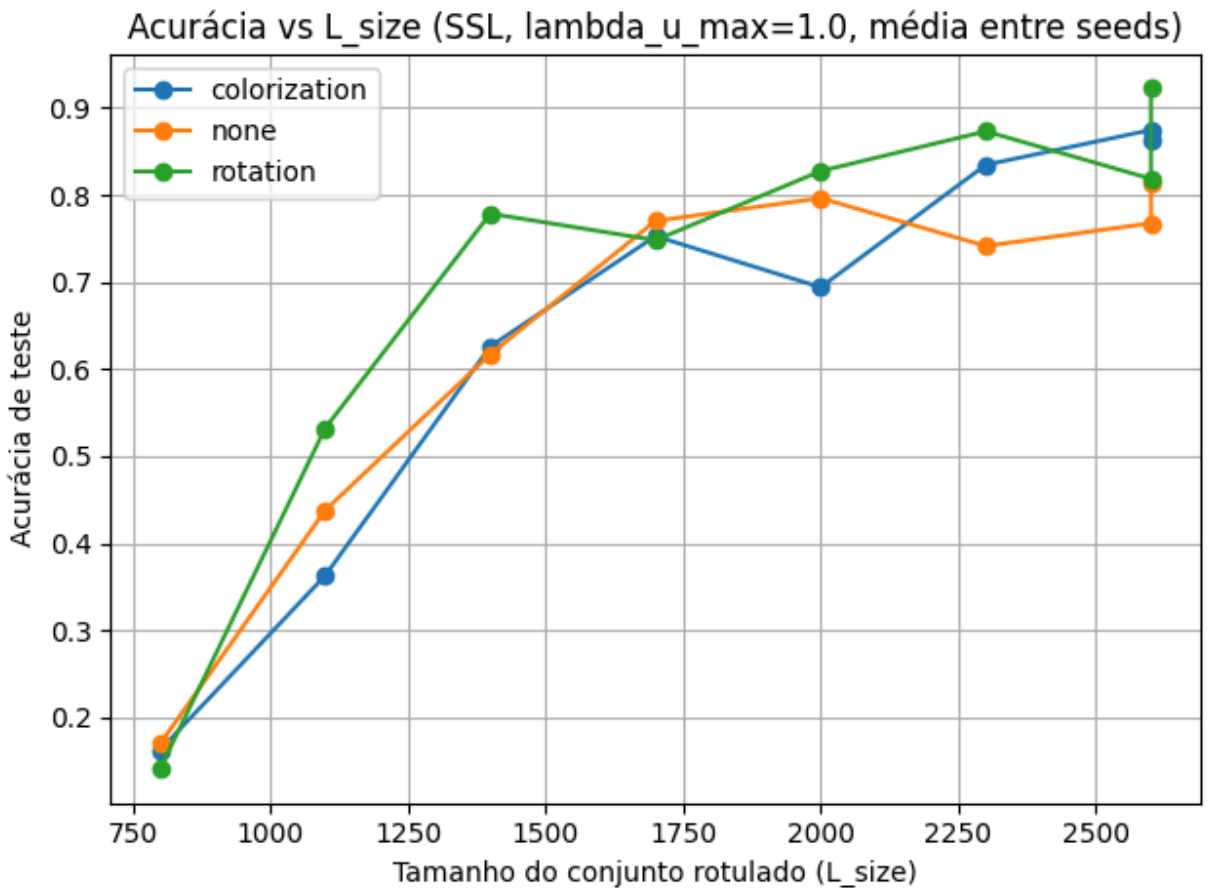

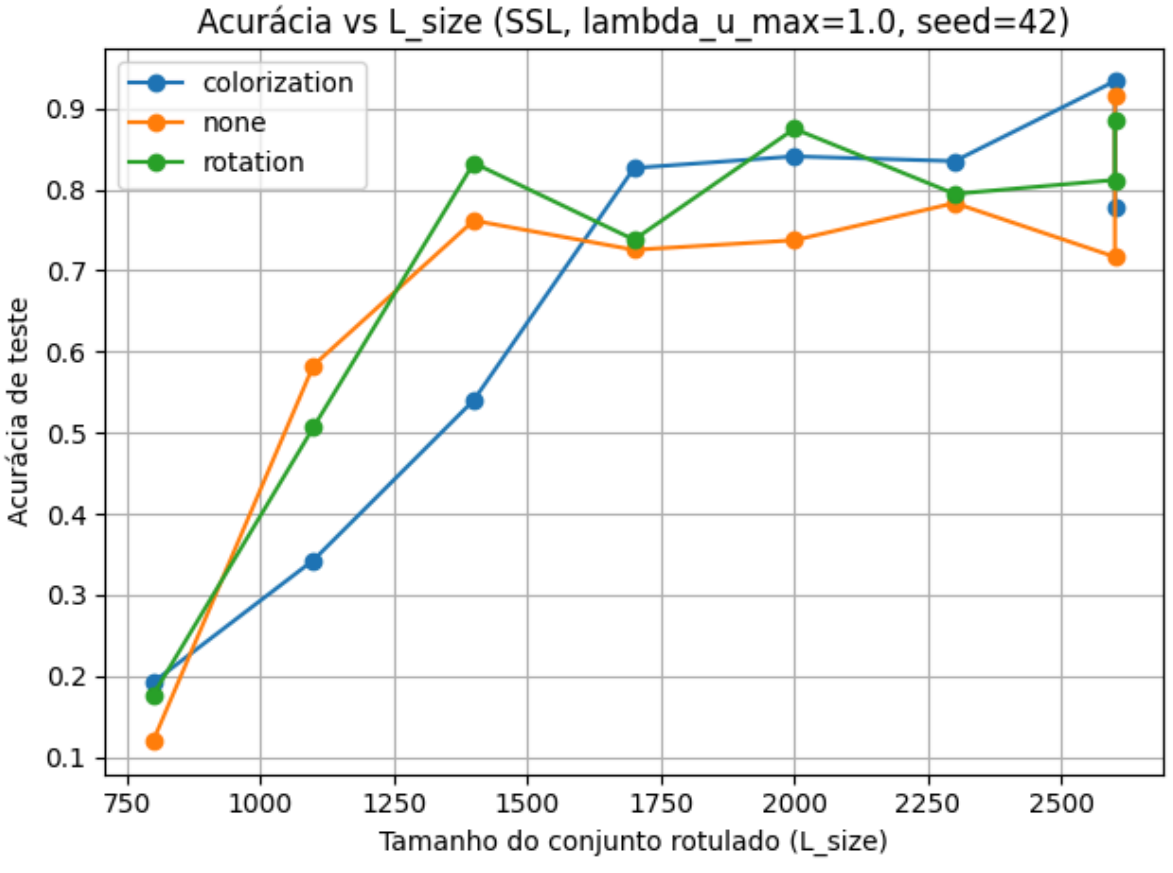



pretext_task	$\lambda_u$	mean_acc	std_acc	mean_time (s)
colorization	1,0	8.635	754	82.277
none (SL puro)	0,0	4.958	236	9.890
none (SSL padrão)	1,0	8.135	1.313	67.013
rotation	1,0	9.169	276	76.853


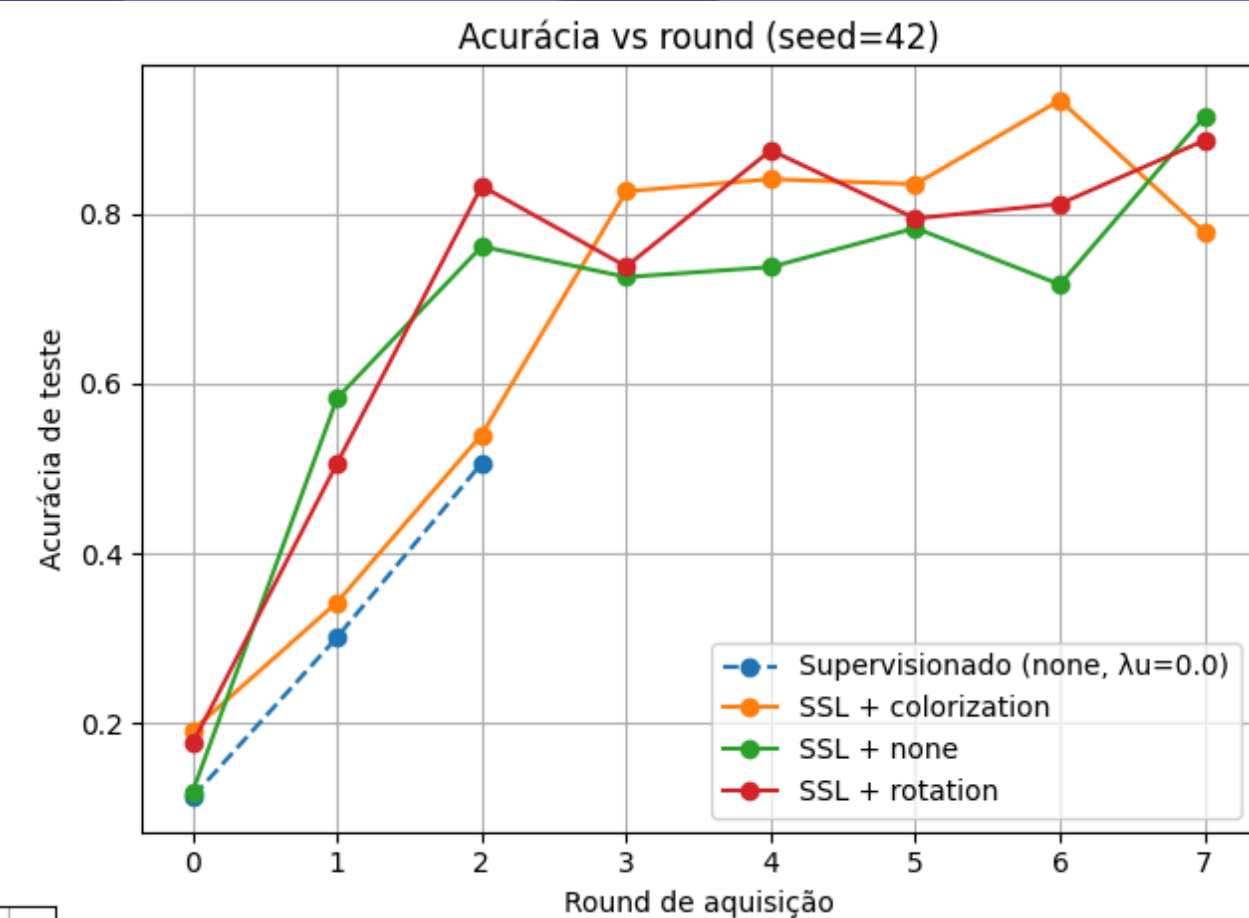

## Desempenho Geral

- **Sl puro**: Demonstra o problema de poucos dados rotulados, justificando o SSL.
- **SLL padrão**: Alta acc mas grande instabilidade (1,313), indica um resultado dependente da semente aleatória.
- **SSL com Colorização**: Alto desempenho de acc com resultado pouco inferior a tarefa com Rotação.
- **SSL com Rotação**: Maior acc para o dataset.


# Resultados e Análise - Acc vs L\_size



# Resultados e Análise - Acc vs Round



# Próximos Passos - Acc final vs Tempo total



- Eficácia da SSL Multitarefa: Pontos agrupados em torno de um tempo de execução maior com acc alta;
- Rotation apresenta pontos na região de maior acc com tempo médio menor em relação a colorization;

# Conclusão

- O uso da Aprendizagem Semissupervisionada (SSL) é crucial para obter alta acurácia neste cenário de escassez inicial de dados rotulados.
- A incorporação de tarefas pretexto (multitarefa) melhora a acurácia e a estabilidade da SSL em comparação com o SSL puro, que é volátil.
- A Tarefa Pretexto de Rotação foi a mais indicada para esse dataset, pois forneceu a maior acurácia final média e a maior consistência entre as diferentes seeds.



# Próximos Passos

- Testar para novos datasets (STL-10, CIFAR-10)
- Comparação com outros métodos que tem o mesmo objetivo (Constrative Learning)
- Testar em arquiteturas maiores com diferentes combinações dos pré-texto.

# Referências

- [1] Amitness, FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence, 2020. Disponível em: <https://amitness.com/posts/fixmatch>
- [2] Sh. Tsang, Review: FixMatch – Simplifying Semi-Supervised Learning with Consistency and Confidence, 2020. Disponível em: <https://sh-tsang.medium.com/review-fixmatch-simplifying-semi-supervised-learning-with-consistency-and-confidence-907ef086a172>
- [3] F. V. Marinho, Active Semi-Supervised Learning CNNs, 2025. Disponível em: <https://github.com/FelippeVeloSoMarinho/ActiveSemisupervisedLearningCNN-s>
- [4] Autor Desconhecido, Survey on Semi-Supervised Learning, 2025. Disponível em: <https://www.molgen.mpg.de/3659531/MITPress--SemiSupervised-Learning.pdf>
- [5] GeeksforGeeks, Self-Supervised Learning (SSL) — An Overview, 2025. Disponível em: <https://www.geeksforgeeks.org/machine-learning/self-supervised-learning-ssl/>